

EMSI

École Marocaine des Sciences de l'Ingénieur

Projet de fin de module

Deep Learning

MLP · CNN · RNN / LSTM / GRU · Seq2Seq

Étudiant : Salaheddine Elberrani – 4IIR

Année universitaire : 2025 – 2026

Plan de la présentation

01

Introduction & Objectifs

02

Partie I – MLP (données tab.)

03

Partie II – CNN (images)

04

Partie III – RNN / Seq2Seq

05

Discussion transversale

06

Conclusion & Résultats clés

Introduction & Objectifs

Objectif général

Adapter le choix d'une architecture de deep learning à la nature des données : tabulaires, images et séquences.

Barème

Partie I – MLP	30 pts
Partie II – CNN	35 pts
Partie III – RNN	35 pts

Données
tabulaires

MLP

PyTorch

Images

CNN

PyTorch

Séquences

RNN/Seq2Seq

PyTorch

Partie I – MLP et ingénierie PyTorch

Architecture & Dataset

Dataset : Wine Quality Red (UCI) – 1 599 éch., 11 features, 6 classes

Architecture : $11 \rightarrow 128 \rightarrow 128 \rightarrow 6$ (18 822 paramètres)

Activation : ReLU + Dropout(0.3)

Deux versions : nn.Sequential et classe personnalisée

Optimiseur : Adam (lr=1e-3, weight_decay=1e-4)


Résultats – Meilleure init. (Xavier)

0.611

Accuracy test

0.598

F1-score (weighted)




Partie I – Comparaison des initialisations

Stratégie	Accuracy	F1-score	Perte val
Gaussienne	0.562	0.548	1.82
Constante	0.523	0.509	2.10
Xavier ✓	0.611	0.598	1.61

Xavier uniforme converge 2× plus vite et +8.8 pts d'accuracy vs constante.

Formule Xavier : $\text{std} = \sqrt{2 / (\text{fan_in} + \text{fan_out})}$



CNN et vision par ordinateur

Fashion-MNIST · LeNet adapté · Feature maps

01

Localité

Chaque filtre ne voit qu'une fenêtre locale — cohérent avec la nature des images

02

Partage des poids

Le même filtre appliqué partout — réduction $\times 8.7$ des paramètres vs MLP

03

Hiérarchie


Couches basses = bords/textures ·
Couches hautes = formes/objets

Partie II – Architecture LeNet adaptée

Couche	Entrée	k / p / s	Sortie	Param s
Conv1 + BN	28×28×1	5 / 2 / 1	28×28×6	156
MaxPool	28×28	2 / 0 / 2	14×14	—
Conv2 + BN	14×14×6	5 / 0 / 1	10×10×16	2 416
MaxPool	10×10	2 / 0 / 2	5×5	—
FC1+FC2+FC3	400	—	10	59 134
TOTAL	—	—	—	61 706

Formule : $H_{out} = \lfloor (H_{in} + 2p - k) / s \rfloor + 1$

Étude expérimentale des choix architecturaux - Fashion-MNIST



Partie II – Comparaison MLP vs CNN

0.889

Accuracy CNN (+conv 1×1)

0.843

Accuracy MLP baseline


+4.6 pts

Gain CNN vs MLP

×8.7

Réduction paramètres

Comparaison MLP vs CNN - Fashion-MNIST



Points clés

MaxPool > AvgPool (+1.4 pts acc)

12 filtres > 6 filtres (+1.1 pts)

Conv 1×1 améliore encore (+0.9 pt)

Feature maps Conv1 = détecteurs de bords (Sobel-like)

CNN 8.7× moins de paramètres que MLP

RNN, LSTM, GRU & Seq2Seq

fra-eng Tatoeba · Language Modeling · Traduction automatique

RNN

Mémoire court terme
Gradients évanescents
1 192 388 params

PPL : 59.0

LSTM

3 portes (oubli, entrée, sortie)
Mémoire long + court terme
1 882 052 params


PPL : 29.5 ★

GRU

2 portes (mise à jour, réinit.)
Bon compromis perf/coût
1 652 164 params

PPL : 35.9

Partie III – BPTT, Gradient Clipping et Perplexité




Gradient Clipping (seuil = 1.0)

Si $\|g\| > \text{seuil} \rightarrow g = g \times \text{seuil} / \|g\|$

Stabilise l'entraînement du RNN (gradients explosifs)

Normes ramenées sous 1.0 à chaque batch





Perplexité : $PPL = \exp(\text{CrossEntropie})$

LSTM : 29.5 (meilleur — portes longue mémoire)

GRU : 35.9 (bon compromis — 2 portes)

RNN : 59.0 (limité — mémoire court terme)

Partie III – Seq2Seq et scores BLEU












Métrique	Greedy	Beam (k=3) ★	Gain
BLEU-1	74.80%	84.74%	+9.9 pts
BLEU-2	43.99%	64.82%	+20.8 pts
PPL val	36.6	36.6	—

Teacher Forcing dégressif (0.8→0.3) + Beam Search avec length penalty → +20.8 pts BLEU-2

Discussion transversale – Synthèse globale

Synthèse globale – Projet Deep Learning EMSI 2025-2026

Partie I : MLP (Wine Quality) | Partie II : CNN (Fashion-MNIST) | Partie III : Seq2Seq (fra-eng)



MLP

Données tabulaires sans structure spatiale — connexion complète justifiée. Limites : déséquilibre classes, opacité.

CNN

Prior inductif fort (localité, invariance). 8.7× moins de params, +4.6 pts accuracy vs MLP.

RNN/Seq2Seq

Mémoire longue distance (LSTM/GRU). Attention manquante = goulot d'étranglement → Transformers.

Conclusion & Résultats clés

0.611

Accuracy MLP
(Wine Quality – Xavier)

0.889

Accuracy CNN
(Fashion-MNIST)

29.5

PPL LSTM
(Language Modeling)

84.7%

BLEU-1 Beam
(fra-eng traduction)

PyTorch maîtrisé : nn.Module, state_dict, device, optimiseurs, schedulers

CNN ×8.7 moins de paramètres que MLP, +4.6 pts accuracy sur Fashion-MNIST

LSTM et GRU résolvent les gradients évanescents du RNN via portes différentiables

Beam Search +20 pts BLEU-2 vs décodage glouton grâce aux k hypothèses parallèles

Prochaine étape naturelle : mécanisme d'attention → Transformers
